

CENTRO UNIVERSITÁRIO IBMEC

CAMPUS BARRA

**MBA EM IA, DATA SCIENCE E BIG
DATA PARA NEGÓCIOS**

ESTATÍSTICA COM R

AULA 4



Sumário

1. Boxplot	3
1.1. Elementos de um boxplot	3
1.2. Utilizando boxplot em R.....	3
1.3. Personalizando Boxplots	3
1.4. Interpretação de Boxplots	4
1.5. Aplicações Práticas.....	4
1.6. Exercícios Práticos	4
1.7. Conclusão	4
2. Testes de Normalidade.....	4
2.1. Conceitos Fundamentais.....	5
2.2. Métodos para Verificar Normalidade	5
2.3. Exemplo Prático no R com o Dataset iris.....	5
2.4. Nível de Confiança	6
2.5. P-valor (p-value).....	6
2.6. Interpretação dos Resultados	7
2.7. Aplicações dos Testes de Normalidade	7
2.8. Exercícios Práticos	7
2.9. Conclusão	7
3. Correlação.....	8
3.1. Tipos de Correlação	8
3.2. Coeficiente de Correlação de Pearson	8
3.3. Matriz de Correlação	9
3.4. Gráfico de Dispersão com Linha de Regressão	9
3.5. Teste de Significância da Correlação.....	9
3.6. Correlação de Spearman e Kendall	10
3.7. Aplicações da Correlação	10
3.8. Exercícios Práticos	10
3.9. Conclusão	10

1. Boxplot

O **boxplot** é uma ferramenta gráfica que resume a distribuição de um conjunto de dados de forma simples e visual. Ele é muito útil para identificar outliers e entender a variação e a distribuição de dados. O boxplot divide os dados em quartis, destacando a mediana e a amplitude interquartil (IQR), que vai do primeiro ao terceiro quartil.

1.1. Elementos de um boxplot

- **Mediana:** A linha dentro da caixa representa a mediana (ou segundo quartil), o ponto onde 50% dos dados estão acima e 50% estão abaixo.
- **Primeiro Quartil (Q1):** A borda inferior da caixa indica o primeiro quartil, que é o ponto abaixo do qual 25% dos dados se encontram.
- **Terceiro Quartil (Q3):** A borda superior da caixa representa o terceiro quartil, onde 75% dos dados estão abaixo desse valor.
- **Amplitude Interquartil (IQR):** É a diferença entre o terceiro e o primeiro quartil, ou seja, $IQR = Q3 - Q1$.
- **Extremos (Whiskers):** As "extensões" ou whiskers representam a amplitude dos dados. Geralmente, eles se estendem até 1.5 vezes o IQR, mas podem ser configurados para outros valores.
- **Outliers:** São dados que estão fora do alcance dos whiskers. Eles são indicados por pontos ou círculos fora da caixa e dos whiskers.

1.2. Utilizando boxplot em R

O R possui funções nativas para a criação de boxplots. A função principal utilizada é `boxplot()`, que permite personalizações diversas.

Exemplo de Criação de Boxplot

Vamos criar um boxplot utilizando o dataset iris, um clássico em análise de dados.

```
# Carregar o dataset iris
data(iris)

# Criar um boxplot da variável Sepal.Length
boxplot(iris$Sepal.Length,
        main = "Boxplot de Sepal Length",
        ylab = "Comprimento da Sépala",
        col = "lightblue")
```

Neste exemplo, criamos um boxplot para a variável `Sepal.Length`, representando o comprimento da sépala das flores do dataset iris.

1.3. Personalizando Boxplots

Podemos personalizar os boxplots para torná-los mais informativos.

```
# Boxplot comparando o comprimento das sépalas por espécie
boxplot(Sepal.Length ~ Species,
        data = iris,
```

```
main = "Boxplot de Sepal Length por Espécie",  
xlab = "Espécie",  
ylab = "Comprimento da Sépala",  
col = c("lightblue", "lightgreen", "lightpink"))
```

Neste exemplo, comparamos a variável Sepal.Length entre as três espécies presentes no dataset iris (setosa, versicolor e virginica).

1.4. Interpretação de Boxplots

- **Simetria:** Se a mediana estiver no centro da caixa e os whiskers forem de tamanhos semelhantes, isso indica que os dados são aproximadamente simétricos.
- **Assimetria (Skewness):** Se a mediana estiver mais próxima de um dos lados da caixa ou se um dos whiskers for significativamente maior que o outro, os dados são assimétricos. Um whisker mais longo à direita indica skewness positiva (cauda direita) e um whisker mais longo à esquerda indica skewness negativa (cauda esquerda).
- **Outliers:** Pontos fora dos whiskers indicam valores atípicos, que podem ser importantes para análise ou para serem tratados, dependendo do contexto.

1.5. Aplicações Práticas

- **Deteção de outliers:** O boxplot é uma ferramenta eficaz para identificar outliers em grandes conjuntos de dados.
- **Comparação entre grupos:** Quando há variáveis categóricas, como no exemplo do dataset iris, o boxplot permite a comparação visual entre diferentes grupos.
- **Análise exploratória de dados:** Antes de realizar análises estatísticas complexas, é sempre recomendável criar boxplots para entender a distribuição dos dados.

1.6. Exercícios Práticos

1. Crie um boxplot para a variável Petal.Length no dataset iris e interprete os resultados.
2. Compare as variáveis Sepal.Width entre as três espécies presentes no dataset iris utilizando um boxplot. O que você pode concluir sobre a distribuição de cada espécie?

1.7. Conclusão

O boxplot é uma poderosa ferramenta de análise exploratória de dados, permitindo uma visualização clara da distribuição e dos outliers. Em análises estatísticas, especialmente em grandes volumes de dados, o boxplot auxilia na identificação de padrões e anomalias, sendo essencial no início de qualquer estudo de dados.

2. Testes de Normalidade

Os testes de normalidade são utilizados para verificar se um conjunto de dados segue uma distribuição normal (ou gaussiana). Em análises estatísticas, muitos testes paramétricos, como o teste t e a ANOVA, assumem que os dados seguem essa distribuição. Portanto, verificar a normalidade dos dados é um passo crucial na análise estatística.

2.1. Conceitos Fundamentais

- **Distribuição Normal:** É uma distribuição de probabilidade simétrica em torno da média, em forma de sino, com a maioria dos dados concentrados ao redor da média e caudas que se afinam nas extremidades.
- **Simetria e Curtose:** A distribuição normal possui simetria perfeita ($\text{skewness} = 0$) e uma curtose padrão ($\text{kurtosis} = 3$).

2.2. Métodos para Verificar Normalidade

Existem várias maneiras de verificar a normalidade de um conjunto de dados, como:

- **Visualização gráfica:** histogramas e boxplots.
- **Testes estatísticos:** Shapiro-Wilk e Kolmogorov-Smirnov.

2.3. Exemplo Prático no R com o Dataset iris

O dataset iris contém variáveis que podem ser usadas para testar a normalidade, como o comprimento da sépala (Sepal.Length). Vamos utilizar essa variável para exemplificar os métodos gráficos e estatísticos de teste de normalidade.

2.3.1. Visualização Gráfica

Uma das maneiras mais comuns de verificar a normalidade é através de gráficos.

- **Histograma:** Um gráfico que exibe a distribuição dos dados em intervalos.

```
# Carregar o dataset iris
data(iris)

# Criar um histograma da variável Sepal.Length
hist(iris$Sepal.Length,
     main = "Histograma de Sepal Length",
     xlab = "Comprimento da Sépala",
     col = "lightblue",
     freq = FALSE)

# Adicionar a curva da distribuição normal ao histograma
lines(density(iris$Sepal.Length), col = "red", lwd = 2)
```

2.3.2. Testes Estatísticos

Os testes estatísticos complementam a análise gráfica e oferecem uma medida quantitativa da normalidade.

- **Teste de Shapiro-Wilk:** Um dos testes mais utilizados para verificar a normalidade, especialmente em amostras pequenas (menores que 2000 observações).

```
# Teste de Shapiro-Wilk para a variável Sepal.Length
shapiro.test(iris$Sepal.Length)
```

O teste de Shapiro-Wilk fornece um valor-p (p-value). Se o valor-p for menor que o nível de significância escolhido (normalmente 0.05), rejeitamos a hipótese nula de que os dados seguem uma distribuição normal.

- **Teste de Kolmogorov-Smirnov:** Embora seja um teste menos poderoso que o Shapiro-Wilk, ele também pode ser usado para verificar a normalidade, especialmente em amostras maiores.

```
# Teste de Kolmogorov-Smirnov para a variável Sepal.Length
ks.test(iris$Sepal.Length, "pnorm", mean(iris$Sepal.Length),
sd(iris$Sepal.Length))
```

Este teste também fornece um valor-p que pode ser usado para concluir sobre a normalidade dos dados.

2.4. Nível de Confiança

O **nível de confiança** é uma medida de quão seguro você está de que o intervalo de confiança (a faixa de valores calculada a partir dos dados da amostra) contém o valor verdadeiro do parâmetro que você está estimando (como a média populacional, por exemplo).

Para ajudar a entender, imagine que você está tentando medir a altura média de todas as pessoas em uma cidade. Como não dá para medir todo mundo, você pega uma amostra. O **nível de confiança** diz o quão confiante você está de que o intervalo calculado (com base nessa amostra) inclui a verdadeira altura média da população.

Se você tiver um nível de confiança de **95%**, isso significa que, se você repetisse o estudo 100 vezes, em 95 dessas vezes, o intervalo de confiança incluiria o valor verdadeiro da altura média.

Exemplo prático:

Se você calcular que a altura média em sua amostra é 170 cm, com um intervalo de confiança de 165 cm a 175 cm e um nível de confiança de 95%, você pode dizer: "Estou 95% confiante de que a verdadeira altura média está entre 165 cm e 175 cm."

2.5. P-valor (p-value)

O **p-valor** é uma medida que ajuda a determinar se o resultado de um teste estatístico é significativo ou não. Ele responde à pergunta: "Quão provável é que eu observe esse resultado, ou um mais extremo, apenas por acaso, se a hipótese nula for verdadeira?"

Considere que:

- A **hipótese nula** é uma afirmação de que não há efeito ou diferença. Por exemplo, você pode estar testando se a média de duas populações é a mesma.
- O **p-valor** indica a probabilidade de observar um resultado tão extremo (ou mais) quanto o que você obteve se a hipótese nula fosse verdadeira.

Se o p-valor for **baixo** (geralmente abaixo de 0,05), você tem evidências suficientes para rejeitar a hipótese nula e concluir que há um efeito ou diferença significativa. Se o p-valor for **alto** (acima de 0,05), você não tem evidências suficientes para rejeitar a hipótese nula, ou seja, o resultado pode ter ocorrido por acaso.

Exemplo prático:

- Suponha que você esteja testando se um novo medicamento é mais eficaz que o atual. Se o teste retornar um **p-valor de 0,03**, significa que há apenas uma chance de 3% de obter esse resultado por acaso, assumindo que o novo medicamento não tem efeito.

- Como o p-valor é menor que 0,05, você pode dizer que o resultado é estatisticamente significativo e que provavelmente o novo medicamento é mais eficaz.

2.6. Interpretação dos Resultados

- **Histograma:** Um histograma com uma forma simétrica e em formato de sino indica que os dados podem ser aproximadamente normais.
- **Gráfico Q-Q:** Se os pontos no gráfico Q-Q seguem uma linha reta, isso sugere que os dados são normalmente distribuídos.
- **Teste de Shapiro-Wilk:** Se o valor-p for maior que 0.05, não podemos rejeitar a hipótese nula, o que sugere que os dados são normalmente distribuídos.
- **Teste de Kolmogorov-Smirnov:** Se o valor-p for maior que 0.05, também sugere que os dados seguem uma distribuição normal.

Exemplo de Interpretação do Teste de Shapiro-Wilk:

```
shapiro.test(iris$Sepal.Length)
```

Saída:

```
# W = 0.97608, p-value = 0.01018
```

Neste exemplo, o valor-p é 0.01018, que é menor que 0.05, o que significa que rejeitamos a hipótese nula. Portanto, a variável Sepal.Length não segue uma distribuição normal.

2.7. Aplicações dos Testes de Normalidade

- **Escolha de Testes Estatísticos:** Se os dados não seguem uma distribuição normal, podemos optar por testes não-paramétricos como o teste de Wilcoxon ou o teste de Kruskal-Wallis.
- **Modelagem Estatística:** A verificação da normalidade é essencial em regressões lineares, ANOVA e outras técnicas paramétricas, onde a suposição de normalidade dos resíduos é fundamental.
- **Análise Exploratória:** Identificar se as variáveis seguem uma distribuição normal pode influenciar na escolha de técnicas de análise de dados e na transformação de variáveis.

2.8. Exercícios Práticos

1. Utilize a variável Petal.Width do dataset iris e faça os seguintes passos:
 - Crie um histograma.
 - Execute o teste de Shapiro-Wilk e interprete os resultados.
2. Aplique o teste de Kolmogorov-Smirnov para a variável Sepal.Width e interprete os resultados.

2.9. Conclusão

Os testes de normalidade são ferramentas essenciais na análise de dados, ajudando a validar a suposição de que os dados seguem uma distribuição normal. Através de métodos gráficos e testes estatísticos, podemos obter *insights* sobre a forma e o comportamento dos dados, orientando as próximas etapas da análise.

3. Correlação

A correlação é uma medida estatística que indica a força e a direção da relação linear entre duas variáveis. No contexto da análise de dados, a correlação é uma ferramenta importante para entender como as variáveis se comportam em conjunto, ajudando a identificar padrões e associações.

3.1. Tipos de Correlação

- **Correlação Positiva:** Quando uma variável aumenta, a outra também tende a aumentar.
- **Correlação Negativa:** Quando uma variável aumenta, a outra tende a diminuir.
- **Correlação Nula:** Quando não há uma relação linear clara entre as variáveis.

A correlação é geralmente representada pelo coeficiente de correlação, com valores que variam de -1 a 1:

- $r=1$: Correlação positiva perfeita.
- $r=-1$: Correlação negativa perfeita.
- $r=0$: Sem correlação linear.

3.2. Coeficiente de Correlação de Pearson

O **coeficiente de correlação de Pearson** é uma medida que avalia a correlação linear entre duas variáveis quantitativas. Ele assume que as variáveis seguem uma distribuição normal e mede a força e a direção da relação linear entre elas.

Interpretação

- $r=1$ indica uma correlação linear positiva perfeita.
- $r=-1$ indica uma correlação linear negativa perfeita.
- $r=0$ indica que não há correlação linear.

O coeficiente de Pearson pode ser influenciado por outliers e pressupõe que as variáveis sejam contínuas e normalmente distribuídas.

Exemplo Prático Usando o Dataset iris

Vamos calcular o coeficiente de correlação de Pearson entre as variáveis Petal.Length e Petal.Width no dataset iris:

```
# Carregar o dataset iris
data(iris)

# Calcular o coeficiente de correlação de Pearson
cor_pearson <- cor(iris$Petal.Length, iris$Petal.Width)

# Exibir o resultado
print(cor_pearson)
```

Interpretação

Se o valor obtido for próximo de 1, significa que há uma forte correlação positiva entre o comprimento e a largura da pétala. Se o valor for próximo de -1, a correlação será negativa. Valores próximos de 0 indicam pouca ou nenhuma correlação.

3.3. Matriz de Correlação

Além de calcular a correlação entre duas variáveis, podemos calcular a correlação entre várias variáveis ao mesmo tempo, gerando uma matriz de correlação.

```
# Selecionar apenas as colunas numéricas
iris_numeric <- iris[, 1:4]

# Calcular a matriz de correlação
cor_matrix <- cor(iris_numeric)

# Exibir a matriz de correlação
print(cor_matrix)
```

Interpretação

A matriz de correlação exibe a correlação entre todas as combinações das variáveis Sepal.Length, Sepal.Width, Petal.Length e Petal.Width. Valores próximos de 1 indicam uma forte correlação positiva, enquanto valores próximos de -1 indicam uma forte correlação negativa.

3.4. Gráfico de Dispersão com Linha de Regressão

Uma boa forma de visualizar a correlação é através de gráficos de dispersão (scatterplots), que podem ser complementados com uma linha de tendência (regressão linear).

```
# Instalar e carregar o pacote ggplot2 para visualização
install.packages("ggplot2")
library(ggplot2)

# Gráfico de dispersão entre Petal.Length e Petal.Width
ggplot(iris, aes(x = Petal.Length, y = Petal.Width)) +
  geom_point() +
  geom_smooth(method = "lm", col = "red") +
  labs(title = "Relação entre Comprimento e Largura da Pétala",
       x = "Comprimento da Pétala",
       y = "Largura da Pétala")
```

Este gráfico mostra a relação entre o comprimento e a largura da pétala. A linha vermelha representa a linha de regressão linear, que pode ser usada para descrever a correlação.

3.5. Teste de Significância da Correlação

Além de calcular o coeficiente de correlação de Pearson, também podemos testar se a correlação observada é significativamente diferente de zero, usando o teste de significância.

```
# Teste de correlação entre Petal.Length e Petal.Width
cor_test <- cor.test(iris$Petal.Length, iris$Petal.Width)

# Exibir os resultados do teste
print(cor_test)
```

Interpretação

O teste retorna um valor-p (p-value) e um coeficiente de correlação. Se o valor-p for menor que 0.05, rejeitamos a hipótese nula, o que significa que existe uma correlação significativa entre as variáveis.

3.6. Correlação de Spearman e Kendall

Quando os dados não seguem uma distribuição normal ou há presença de outliers, os coeficientes de correlação de Spearman ou Kendall podem ser mais apropriados.

- **Correlação de Spearman:** Usa o ranking dos dados e é menos sensível a outliers.
- **Correlação de Kendall:** Similar a Spearman, mas baseada na concordância e discordância dos pares de observações.

```
# Correlação de Spearman entre Sepal.Length e Sepal.Width
cor_spearman <- cor(iris$Sepal.Length, iris$Sepal.Width, method = "spearman")
print(cor_spearman)

# Correlação de Kendall entre Sepal.Length e Sepal.Width
cor_kendall <- cor(iris$Sepal.Length, iris$Sepal.Width, method = "kendall")
print(cor_kendall)
```

3.7. Aplicações da Correlação

- **Análise Exploratória de Dados:** Identificar rapidamente relações entre variáveis.
- **Modelagem Preditiva:** A correlação ajuda a selecionar variáveis que podem ser usadas em modelos preditivos.
- **Multicolinearidade:** Em regressões, alta correlação entre variáveis independentes pode indicar multicolinearidade, o que prejudica a interpretação dos coeficientes.

3.8. Exercícios Práticos

1. Calcule a matriz de correlação para o dataset iris e interprete os valores para as variáveis Sepal.Length e Sepal.Width.
2. Crie um gráfico de dispersão para as variáveis Petal.Length e Petal.Width, e inclua uma linha de regressão. O que a relação entre essas variáveis indica?
3. Realize o teste de correlação de Spearman entre Sepal.Length e Sepal.Width. Como a correlação de Spearman difere da correlação de Pearson para esses dados?

3.9. Conclusão

A correlação é uma ferramenta estatística poderosa para medir a relação entre variáveis. Ao aplicar correlação no R, é possível não apenas calcular os coeficientes, mas também visualizar graficamente essas

relações e testar sua significância. Com isso, a análise de correlação pode fornecer insights valiosos sobre os padrões presentes nos dados.