

CENTRO UNIVERSITÁRIO IBMEC

CAMPUS BARRA

**MBA EM IA, DATA SCIENCE E BIG
DATA PARA NEGÓCIOS**

ESTATÍSTICA COM R

AULA 5



Sumário

1. Aprendizado de Máquina	3
1.1. Aprendizado Supervisionado	3
1.1.1 Problemas de Predição (Regressão)	3
1.1.2 Problemas de Classificação	4
2. Regressão Linear Simples	4
2.1. Explorando o dataset iris	4
2.2. Análise Exploratória Inicial	5
2.3. Ajustando o Modelo de Regressão Linear	5
2.4. Interpretação do <code>summary(modelo)</code>	5
2.5. Visualizando a Reta de Regressão	5
2.6. Diagnóstico do Modelo	6
2.7. Fazendo Previsões	6
2.8. Interpretação	6
3. Regressão Logística	6
3.1. Preparando o dataset	6
3.2. Ajustando o modelo	7
3.3. Interpretação	7
3.4. Fazendo previsões	7
3.5. Visualizando o modelo	7
3.6. Avaliando a acurácia	8
3.7. Extensão para 3 classes	8
3.8. Conclusão	8

1. Aprendizado de Máquina

A área de **Machine Learning (Aprendizado de Máquina)** estuda algoritmos e modelos capazes de **aprender padrões a partir de dados e realizar previsões ou classificações**, sem serem explicitamente programados para isso. Em essência, o objetivo é permitir que um sistema melhore seu desempenho conforme é exposto a mais exemplos, extraíndo relações entre variáveis de forma autônoma. Os algoritmos de aprendizado de máquina são tradicionalmente divididos em três grandes categorias: **aprendizado supervisionado**, quando o modelo aprende a partir de dados rotulados (como regressão e classificação); **aprendizado não supervisionado**, quando identifica estruturas ocultas em dados sem rótulos (como agrupamentos e redução de dimensionalidade); e **aprendizado por reforço**, em que o agente aprende por meio de interações com o ambiente, recebendo recompensas ou penalidades conforme suas ações.

Do ponto de vista conceitual, o Machine Learning é uma **extensão prática da Inferência Estatística** — enquanto a estatística busca **entender e explicar relações** entre variáveis a partir de uma amostra, o aprendizado de máquina enfatiza a **capacidade de generalizar e prever** novos resultados com alta acurácia. Em ambos os casos, há um processo de estimar parâmetros e avaliar incertezas, mas com ênfases distintas: a estatística se preocupa com **interpretação e significância**, enquanto o aprendizado de máquina prioriza **desempenho preditivo**. Assim, os modelos de regressão, classificação e clustering podem ser vistos como uma ponte entre esses dois mundos — a **racionalidade analítica da estatística** e a **capacidade adaptativa da inteligência artificial**.

1.1. Aprendizado Supervisionado

O aprendizado supervisionado ocorre quando fornecemos ao algoritmo **pares de entrada e saída**, para que ele **descubra o padrão que relaciona as duas coisas**, por exemplo:

- Entrada (X): características de uma flor, como o comprimento da pétala e da sépala.
- Saída (Y): o nome da espécie (*setosa*, *versicolor* ou *virginica*).

O modelo é “supervisionado” porque ele sabe qual é a resposta correta durante o treino. Depois de treinado, ele deve conseguir **prever a saída correta** para novos dados que nunca viu antes.

Os problemas de aprendizado supervisionado podem ser divididos em dois grandes grupos: **problemas de predição (ou regressão)** e **problemas de classificação**.

1.1.1 Problemas de Predição (Regressão)

Nos problemas de **predição**, a saída (Y) é **numérica e contínua**. O objetivo é **estimar valores quantitativos** com base em variáveis explicativas.

Exemplos:

- Prever o preço de um imóvel a partir de seu tamanho e localização.
- Estimar a temperatura de amanhã com base em dados climáticos de hoje.
- Calcular o comprimento médio da sépala de uma flor a partir do comprimento da pétala (como no dataset *iris*).

Esses modelos geram **números como resultado** e são chamados de **modelos de regressão**. A **regressão linear simples** é o modelo mais básico e interpretável dessa categoria.

1.1.2 Problemas de Classificação

Nos problemas de **classificação**, a saída (**Y**) é **categórica ou discreta**. O objetivo é **atribuir uma classe ou rótulo** a cada observação com base em suas características.

Exemplos:

- Classificar e-mails em "spam" ou "não spam".
- Diagnosticar uma doença (positivo/negativo).
- Determinar a espécie de uma flor (setosa, versicolor ou virginica) com base em suas medidas.

Aqui, o modelo responde **com categorias**, e não com números. Os algoritmos mais conhecidos incluem **árvores de decisão**, **k-vizinhos mais próximos (k-NN)** e **regressão logística** (apesar do nome, é um modelo de classificação).

2. Regressão Linear Simples

A **regressão linear simples** é uma técnica estatística usada para modelar a relação entre **uma variável dependente (Y)** e **uma variável independente (X)**. Seu objetivo é ajustar uma reta que melhor descreva essa relação.

A equação do modelo é:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

onde:

- Y: variável dependente (ou resposta);
- X: variável independente (ou explicativa);
- β_0 : intercepto (valor de Y quando $X = 0$);
- β_1 : coeficiente angular (variação média de Y para cada unidade de X);
- ε : erro aleatório.

Podemos investigar se existe relação entre o **comprimento da sépala (Sepal.Length)** e o **comprimento da pétala (Petal.Length)** no dataset iris.

2.1. Explorando o dataset iris

O dataset iris é nativo do R e contém 150 observações de flores de três espécies: *setosa*, *versicolor* e *virginica*.

```
# Carregar o dataset
data(iris)

# Visualizar as primeiras linhas
head(iris)

# Estrutura do dataset
str(iris)
```

Principais variáveis numéricas:

- Sepal.Length — comprimento da sépala (cm)
- Sepal.Width — largura da sépala (cm)
- Petal.Length — comprimento da pétala (cm)
- Petal.Width — largura da pétala (cm)

2.2. Análise Exploratória Inicial

Antes de ajustar o modelo, é essencial visualizar a relação entre as variáveis.

```
# Gráfico de dispersão
plot(iris$Petal.Length, iris$Sepal.Length,
     main = "Dispersão: Petal.Length x Sepal.Length",
     xlab = "Comprimento da Pétala (cm)",
     ylab = "Comprimento da Sépala (cm)",
     pch = 19, col = "blue")
```

O gráfico de dispersão ajuda a identificar se há uma **tendência linear** — neste caso, observa-se que quanto maior a pétala, maior tende a ser a sépala.

2.3. Ajustando o Modelo de Regressão Linear

O ajuste é feito com a função `lm()` (linear model):

```
# Modelo de regressão linear simples
modelo <- lm(Sepal.Length ~ Petal.Length, data = iris)

# Exibir o resumo do modelo
summary(modelo)
```

2.4. Interpretação do `summary(modelo)`

O *output* apresenta:

Termo	Interpretação
(Intercept)	Valor esperado de Sepal.Length quando Petal.Length = 0
Petal.Length	Variação média de Sepal.Length para cada unidade de aumento em Petal.Length
R-squared (R²)	Proporção da variabilidade de Sepal.Length explicada por Petal.Length
p-value	Significância estatística dos coeficientes

Se o p-valor do coeficiente for menor que 0.05, há evidência de relação linear significativa.

2.5. Visualizando a Reta de Regressão

Podemos adicionar a reta ajustada ao gráfico:

```
# Gráfico com linha de regressão
plot(iris$Petal.Length, iris$Sepal.Length,
```

```
main = "Regressão Linear Simples",  
xlab = "Comprimento da Pétala (cm)",  
ylab = "Comprimento da Sépala (cm)",  
pch = 19, col = "darkgreen")
```

```
abline(modelo, col = "red", lwd = 2)
```

2.6. Diagnóstico do Modelo

É importante verificar se os resíduos se comportam aleatoriamente (sem padrão definido).

```
# Plotar os resíduos  
plot(modelo$residuals,  
      main = "Resíduos do Modelo",  
      ylab = "Resíduo", xlab = "Índice da Observação",  
      col = "purple", pch = 19)  
abline(h = 0, col = "red", lty = 2)
```

Resíduos distribuídos aleatoriamente em torno de zero indicam que o modelo é adequado.

2.7. Fazendo Previsões

Com o modelo ajustado, podemos prever novos valores de Sepal.Length a partir de novos valores de Petal.Length.

```
# Novos valores para previsão  
novos_dados <- data.frame(Petal.Length = c(1.5, 4.5, 6.0))  
  
# Previsões  
predict(modelo, novos_dados)
```

2.8. Interpretação

Suponha que o modelo retornou:

$$\text{Sepal.Length} = 4.31 + 0.41 \times \text{Petal.Length}$$

Isso significa que:

- Quando o comprimento da pétala é **0**, o comprimento estimado da sépala é **4.31 cm**.
- A cada **1 cm** de aumento no comprimento da pétala, o comprimento da sépala **aumenta em média 0.41 cm**.

3. Regressão Logística

A regressão logística é usada quando a **variável dependente é categórica**, ou seja, quando queremos **classificar** as observações em **grupos** (espécies, neste caso), com base em variáveis numéricas como o comprimento e a largura das pétalas e sépalas.

3.1. Preparando o dataset

O iris possui três espécies (*setosa*, *versicolor*, *virginica*), então podemos começar com uma **regressão logística binária**, selecionando apenas duas espécies para simplificar:


```
# Filtrar duas espécies para regressão logística binária
iris_bin <- subset(iris, Species != "virginica")

# Conferir o conjunto filtrado
table(iris_bin$Species)
```

3.2. Ajustando o modelo

Vamos prever a **espécie da flor (Setosa ou Versicolor)** com base em uma variável contínua, por exemplo Petal.Length.

```
# Ajustar o modelo de regressão logística
modelo_log <- glm(Species ~ Petal.Length,
                  data = iris_bin,
                  family = binomial)

# Resumo do modelo
summary(modelo_log)
```

3.3. Interpretação

A equação ajustada é:

$$\log(p/1-p) = \beta_0 + \beta_1 \times \text{Petal.Length}$$

onde:

- p é a **probabilidade de a flor ser “versicolor”**;
- β_0 é o intercepto;
- β_1 é o coeficiente que mostra como o comprimento da pétala influencia essa probabilidade.

Se $\beta_1 > 0$, quanto maior o comprimento da pétala, **maior a probabilidade de a flor ser versicolor**.

3.4. Fazendo previsões

```
# Previsões de probabilidade
iris_bin$prob <- predict(modelo_log, type = "response")

# Visualizar primeiras linhas
head(iris_bin)
```

3.5. Visualizando o modelo

```
# Gráfico das probabilidades
plot(iris_bin$Petal.Length, iris_bin$prob,
     main = "Regressão Logística: Probabilidade de ser Versicolor",
     xlab = "Comprimento da Pétala (cm)",
     ylab = "Probabilidade",
     pch = 19, col = "darkgreen")

# Adicionar linha de tendência
curve(predict(modelo_log, newdata = data.frame(Petal.Length = x),
            type = "response"),
      add = TRUE, col = "red", lwd = 2)
```

Você verá uma **curva sigmoide (em forma de "S")**, característica da regressão logística.

3.6. Avaliando a acurácia

Podemos transformar as probabilidades em classes preditas e comparar com as reais:

```
# Converter probabilidades em classes (limiar de 0.5)
iris_bin$pred <- ifelse(iris_bin$prob > 0.5, "versicolor", "setosa")

# Matriz de confusão
table(iris_bin$Species, iris_bin$pred)
```

3.7. Extensão para 3 classes

A versão com as três espécies requer **regressão logística multinomial**, que pode ser feita com o pacote `nnet`:

```
library(nnet)

# Modelo multinomial
modelo_multi <- multinom(Species ~ Petal.Length + Petal.Width, data = iris)

summary(modelo_multi)
```

Esse modelo gera uma equação logística para cada espécie, comparando-a com uma categoria de referência.

3.8. Conclusão

Tipo de Regressão	Tipo de Saída	Exemplo no iris	Forma da Relação
Linear	Numérica	Predizer Sepal.Length a partir de Petal.Length	Reta
Logística	Categórica	Classificar a espécie (setosa ou versicolor)	Curva sigmoide

A regressão logística é o **elo natural entre estatística clássica e aprendizado de máquina supervisionado**, sendo a base de algoritmos como **redes neurais** e **softmax regression**.